Tarea # 1 Máquinas de Aprendizaje

Rafik Mas'ad
Alejandro Sazo

September 9, 2016

1 Tarea 1 Máquinas de Aprendizaje

1.1 Ejercicio 1

(a) Construcción del dataframe. La primera columna del dataframe original es redundante para la indexación, mientras que la columna Train nos permite identificar cuales ejemplos serán parte del training set (Train = T) y del testing set (Train = F). Para explicitar qué ejemplos son del testing set se invierten los valores de verdad de dicha columna. Finalmente la columna ya utilizada se descarta para quedarnos con las columnas de predictores.

```
In [1]: import numpy as np
        import pandas as pd

        url = 'http://statweb.stanford.edu/~tibs/ElemStatLearn/datasets/prostate.da
        df = pd.read_csv(url, sep='\t', header=0)
        # Remover columna con indices redundantes
        df = df.drop('Unnamed: 0', axis=1)
        # Obtener columna con la etiqueta Train y reemplazar valores booleanos. Est
        istrain_str = df['train']
        istrain = np.asarray([True if s == 'T' else False for s in istrain_str])
        # Listar como testing el resto de valores falsos de la columna anterior
        istest = np.logical_not(istrain)
        # Una vez procesado los datos, eliminar la columna train para almacenar los
        df = df.drop('train', axis=1)
```

(b) Descripción del dataset. El dataset posee 9 atributos y 97 samples con valores enteros y reales.

```
In [2]: df.shape
        df.info()
        df.describe()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 97 entries, 0 to 96
Data columns (total 9 columns):
lcavol     97 non-null float64
lweight    97 non-null float64
```

```
age         97 non-null int64
lbph        97 non-null float64
svi         97 non-null int64
lcp         97 non-null float64
gleason     97 non-null int64
pgg45       97 non-null int64
lpsa        97 non-null float64
dtypes: float64(5), int64(4)
memory usage: 7.6 KB
```

Out[2]:

	lcavol	lweight	age	lbph	svi	lcp
count	97.000000	97.000000	97.000000	97.000000	97.000000	97.000000
mean	1.350010	3.628943	63.865979	0.100356	0.216495	-0.179366
std	1.178625	0.428411	7.445117	1.450807	0.413995	1.398250
min	-1.347074	2.374906	41.000000	-1.386294	0.000000	-1.386294
25%	0.512824	3.375880	60.000000	-1.386294	0.000000	-1.386294
50%	1.446919	3.623007	65.000000	0.300105	0.000000	-0.798508
75%	2.127041	3.876396	68.000000	1.558145	0.000000	1.178655
max	3.821004	4.780383	79.000000	2.326302	1.000000	2.904165

	gleason	pgg45	lpsa
count	97.000000	97.000000	97.000000
mean	6.752577	24.381443	2.478387
std	0.722134	28.204035	1.154329
min	6.000000	0.000000	-0.430783
25%	6.000000	0.000000	1.731656
50%	7.000000	15.000000	2.591516
75%	7.000000	40.000000	3.056357
max	9.000000	100.000000	5.582932

(c) Normalización de datos. Este preprocesamiento de los datos es importante pues las features originales pueden venir en distintas escalas por lo tanto nuestro algoritmo de aprendizaje no funcionará correctamente, por ejemplo al utilizar funciones objetivo que incluyan métricas, los datos con mayor rango tenderán a dominar sobre los de menor rango; por otra parte también podría darse el caso de que la convergencia en algoritmos que usen gradiente descendiente sea lenta o imprecisa.

```
In [3]: from sklearn.preprocessing import StandardScaler
        # Por defecto centra y escala la data.
        scaler = StandardScaler(with_mean=True, with_std=True)
        df_scaled = pd.DataFrame(scaler.fit_transform(df), columns=df.columns)
        #  Deseamos aprender a predecir el feature lpsa, por lo que la recuperamos
        df_scaled['lpsa'] = df['lpsa']
```

(d) Regresión lineal con Mínimos Cuadrados. En primer lugar extraemos la última columna de los datos, que corresponde al output y de cada ejemplo. La nueva columna añadida corresponde al bias. El argumento pasado al constructor de LinearRegression indica que no

se calculará intercepto para el modelo (ya lo hemos hecho a través de normalizar e ingresar la columna con bias 1)

```
In [4]: import sklearn.linear_model as lm
        X = df_scaled.ix[:,:-1]
        # Agregamos la columna de bias con 1
        N = X.shape[0]
        X.insert(X.shape[1], 'intercept', np.ones(N))
        # Obtener los datos de output conocidos y extraer test & training set
        y = df_scaled['lpsa']
        Xtrain = X[istrain]
        ytrain = y[istrain]
        Xtest = X[istest]
        ytest = y[istest]
        linreg = lm.LinearRegression(fit_intercept=False)
        linreg.fit(Xtrain, ytrain)

Out[4]: LinearRegression(copy_X=True, fit_intercept=False, n_jobs=1, normalize=Fals
```

(e) Tabla de pesos (coeficientes) y Z-scores para cada variable. Los Z-scores miden el efecto de descartar alguna variable del modelo. Cuando deseamos un 5% de significancia, las variables que resultarán más importantes deberán tener Z-score en valor abosluto mayor que 2, lo que indica una significancia del 5%. Las variables mas importante por lo tanto son en orden de Z-score decreciente **lcavol**, **svi**, **lcp** y **pgg45**

```
In [5]: # Correlacion entre variables
        # print Xtrain.drop('intercept', axis=1).corr()

        # Tabla con coefficientes y sus Z-score
        coeffs = linreg.coef_
        Table = pd.DataFrame(coeffs, index=X.columns, columns=['Coefficent'])
        Table['Std. Error'] = Xtrain.std() / np.sqrt(Xtrain.shape[0])
        Table['Z-score'] = Table['Coefficent'].div(Table['Std. Error'], axis=0)
        Table

Out[5]:            Coefficent  Std. Error   Z-score
        lcavol       0.676016    0.129469  5.221460
        lweight      0.261694    0.136618  1.915519
        age         -0.140734    0.123746 -1.137281
        lbph         0.209061    0.123892  1.687447
        svi          0.303623    0.124582  2.437133
        lcp         -0.287002    0.123022 -2.332923
        gleason     -0.021195    0.120547 -0.175822
        pgg45        0.265576    0.127584  2.081583
        intercept    2.464933    0.000000       inf
```

(f) Estimación de errores de predicción. El uso de cross validation nos permitirá entender que tan bien generaliza nuestra máquina mientras no tengamos disponible el testing set. La máquina entrenando con 5 folds presenta un MSE (Mean squared error o error cuadrático

medio) de 0.95, mientras que con 10 folds el MSE disminuye a 0.75. El MSE en el testing set es finalmente de 0.5, lo cual es positivo pues nuestro modelo original tenía un alto error en el training set, pero las pruebas sobre el testing set fueron mejores.

```
In [6]: # Predecir en el testing set
        yhat_test = linreg.predict(Xtest)
        # Calcular error cuadrático medio en el testing set
        mse_test = np.mean(np.power(yhat_test - ytest, 2))
        print "MSE para testing set:", mse_test
        from sklearn import cross_validation
        Xm = Xtrain.as_matrix()
        ym = ytrain.as_matrix()
        # Definir numero de folds
        n_folds = [5, 10]
        # Estimar error con 5 y 10 folds
        for nf in n_folds:
            k_fold = cross_validation.KFold(len(Xm), nf)
            # MSE para cross validation
            mse_cv = 0
            for k, (train, val) in enumerate(k_fold):
                linreg = lm.LinearRegression(fit_intercept = False)
                # Modelar con el subconjunto del training set dado por el fold
                linreg.fit(Xm[train], ym[train])
                yhat_val = linreg.predict(Xm[val])
                mse_fold = np.mean(np.power(yhat_val - ym[val], 2))
                mse_cv += mse_fold
            mse_cv = mse_cv / nf
            print "MSE para",nf,"folds:",mse_cv
```

```
MSE para testing set: 0.521274005508
MSE para 5 folds: 0.956514631616
MSE para 10 folds: 0.757237472963
```

j) QQ Plot para error de prueba. Podemos observar que $R^2 = 0.9537$, lo que indica una alta correlación entre los datos de predicción, por lo que es razonable suponer que los residuos se distribuyen de forma normal.

```
In [7]: %matplotlib inline
        import matplotlib.pyplot as plt
        import scipy.stats as stats
        residual = yhat_test - ytest
        plt.figure(figsize=(6,6))
        stats.probplot(residual, dist="norm", plot=plt)
        plt.title("Q-Q Plot")
        plt.xlabel("Quantiles")
        plt.ylabel("Residuos")
        plt.show()
```

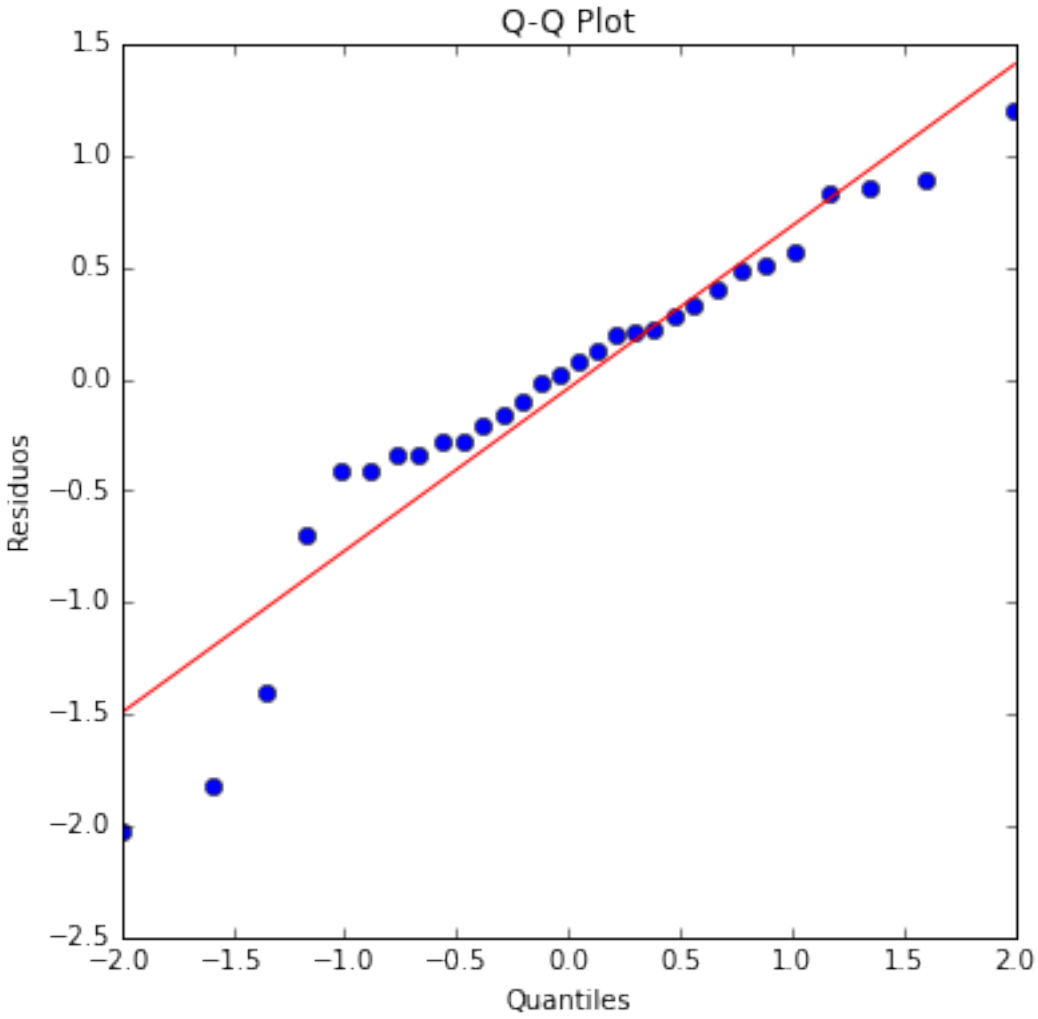

1.2 Ejercicio 2

(a) Implementación de FSS. En vez de simplemente usar el error cuadrático medio como criterio para aceptar o no una variable se ha implementado una versión que utiliza el coeficiente R^2. Gráficamente los errores de entrenamiento siempre decrecen, pero con 5 variables los errores en el conjunto de test son del orden de 0.45, añadir más variables aumenta el error de test a partir de ese punto

```
In [8]: def fss(x, y, x_test, y_test, names_x, k = 10000):
            """
                Forward Step-wise Selection
                Args:
                    x: Training set x
                    y: Training set y
                    x_test: Testing set x
```

```
        y_test: Testing set y
        names_x: Labels for training set x
        k: Max number of variables
"""
# Numero de features
p = x.shape[1]-1
k = min(p, k)
names_x = np.array(names_x)
remaining = range(0, p)
# Mantener intercepto
selected = [p]
current_score = 0.0
best_new_score = 0.0
nvars = []
training_errors = []
test_errors = []
# Mientras hayan candidatos y las variables seleccionadas no superen k
while remaining and len(selected) <= k:
    score_candidates = []
    # Por cada variable candidata
    for candidate in remaining:
        # Crear un nuevo modelo de regresion
        model = lm.LinearRegression(fit_intercept=False)
        indexes = selected + [candidate]
        # Extraer como conjunto de entrenamiento el intercepto
        # y los valores asociados a las variables elegidas
        x_train = x[:,indexes]
        # Hacer el fit del modelo y predecir
        model.fit(x_train, y)
        # Predecir sobre training y test
        _x_test = x_test.as_matrix()[:,indexes]
        yhat_train = model.predict(x_train)
        yhat_test = model.predict(_x_test)
        # Obtener residuos y calcular R^2
        residuals_train = yhat_train - y
        residuals_test = yhat_test - y_test
        # Calcular Error de entrenamiento
        training_error = np.mean(np.power(residuals_train,2))
        test_error = np.mean(np.power(residuals_test, 2))
        mean_y = np.mean(y)
        SS_tot = np.sum(np.power(y-mean_y,2))
        SS_res = np.sum(np.power(residuals_train,2))
        R2 = 1 - (SS_res/SS_tot)
        score_candidates.append((R2, candidate, training_error, test_er
    # Una vez analizadas las candidatas ordenar scores de mayor a meno
    score_candidates.sort()
    # Extraer el elemento de mejor score
    best_new_score, best_candidate, best_training_error, best_test_erro
```

```
                # Remover al candidato de la lista de restantes y agregarlo a la li
                remaining.remove(best_candidate)
                selected.append(best_candidate)
                nvars.append(len(indexes))
                training_errors.append(best_training_error)
                test_errors.append(best_test_error)
                # R^2 correspondiente a esta configuracion para testing set
                print "selected = %s ..."%names_x[best_candidate]
                print "totalvars=%d, R^2 = %f"%(len(indexes),best_new_score)
            return selected, nvars, training_errors, test_errors

        names_regressors = ["Lcavol", "Lweight", "Age", "Lbph", "Svi", "Lcp", "Glea
        selected, nvars, training_errors, test_errors = fss(Xm, ym, Xtest, ytest, r
        plt.figure(figsize=(6,6))
        plt.plot(nvars, training_errors, 'bo-', label="Training error")
        plt.plot(nvars, test_errors, 'ro-', label="Test error")
        plt.legend()
        plt.xlabel("# variables")
        plt.ylabel("MSE")
        plt.show()
```

```
selected = Lcavol ...
totalvars=2, R^2 = 0.537516
selected = Lweight ...
totalvars=3, R^2 = 0.614756
selected = Svi ...
totalvars=4, R^2 = 0.637441
selected = Lbph ...
totalvars=5, R^2 = 0.659176
selected = Pgg45 ...
totalvars=6, R^2 = 0.666920
selected = Lcp ...
totalvars=7, R^2 = 0.682807
selected = Age ...
totalvars=8, R^2 = 0.694258
selected = Gleason ...
totalvars=9, R^2 = 0.694371
```

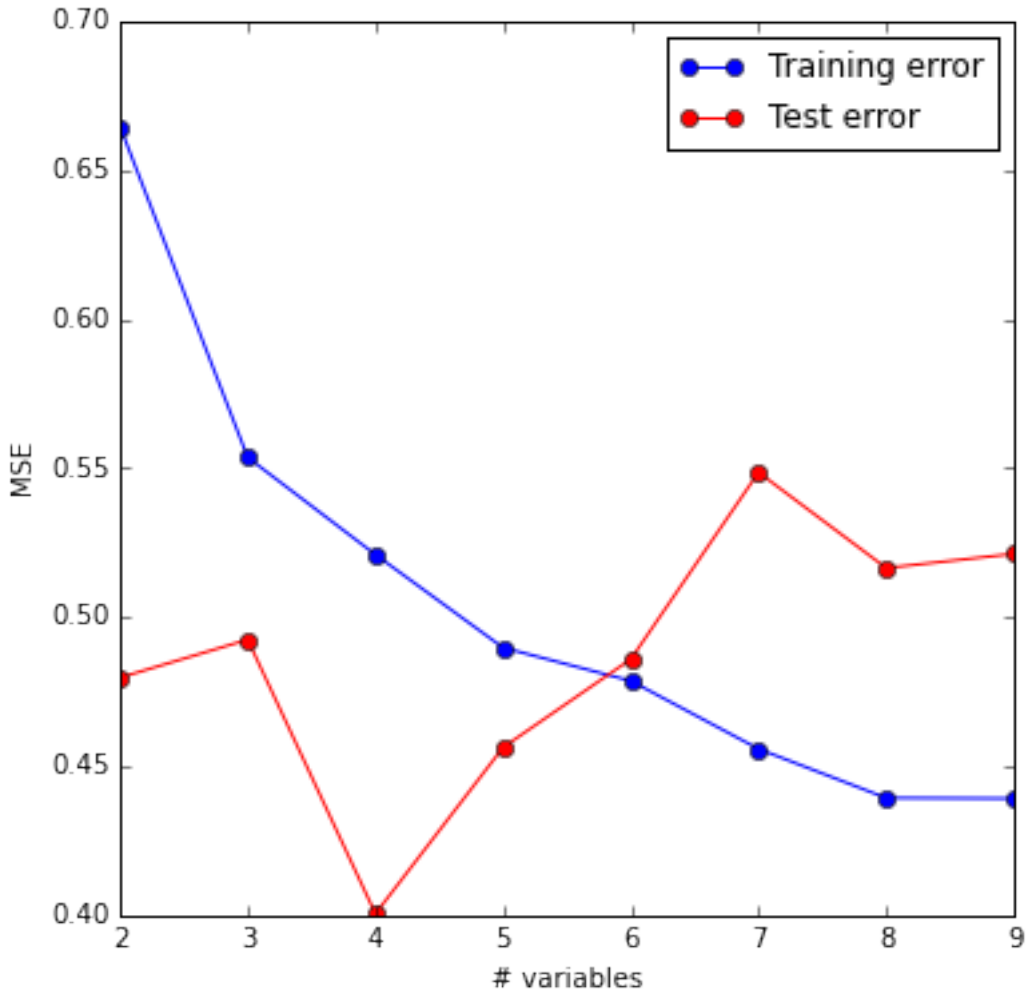

(b) Implementación de BSS. Se mantiene la forma de calcular el score anterior. En este caso los resultados obtenidos son consistentes con la implementación de FSS. Con este dataset y score es posible apreciar que ambos algoritmos llegan a una zona donde los errores de testing son inferiores a 0.5 y menores a los errores de entrenamiento (modelo 2 a 5 variables).

```
In [9]: def bss(x, y, x_test, y_test, names_x):
            names_x = np.array(names_x)
            # Inicialmente no descartamos ningun valor
            dropped = []
            # Las variables del modelo son todas las originales
            variables = range(0, x.shape[1])
            nvars = []
            training_errors = []
            test_errors = []
            # Mientras hayan variables
            while len(variables) > 1:
```

```
            scores = []
            # Por cada variable verificar cual es aquella que menos influye
            for candidate in variables:
                # Crear un nuevo modelo de regresion
                model = lm.LinearRegression(fit_intercept=False)
                indexes = []
                indexes[:] = variables + [x.shape[1]-1]
                # Remover una variable
                indexes.remove(candidate)
                x_train = x[:,indexes]
                # Hacer el fit del modelo y predecir
                model.fit(x_train, y)
                # Predecir sobre training y test
                _x_test = x_test.as_matrix()[:,indexes]
                yhat_test = model.predict(_x_test)
                yhat_train = model.predict(x_train)
                # Obtener residuos y calcular R^2
                residuals_train = yhat_train - y
                residuals_test = yhat_test - y_test
                # Calcular Error de entrenamiento
                training_error = np.mean(np.power(residuals_train,2))
                test_error = np.mean(np.power(residuals_test, 2))
                mean_y = np.mean(y)
                SS_tot = np.sum(np.power(y-mean_y,2))
                SS_res = np.sum(np.power(residuals_train,2))
                # Calcular R^2 para cada modelo
                R2 = 1 - (SS_res/SS_tot)
                scores.append((R2, candidate, training_error, test_error))
            scores.sort()
            best_new_score, drop_candidate, best_training_error, best_test_erro
            #score_dropped[:] = score_dropped[::-1]
            #worst_new_score, worst_candidate, worst_training_error, worst_test
            variables.remove(drop_candidate)
            dropped.append(drop_candidate)
            nvars.append(len(indexes))
            training_errors.append(best_training_error)
            test_errors.append(best_test_error)
            # R^2 correspondiente a esta configuracion para testing set
            if(len(variables) == x.shape[1]-1):
                print "No variables dropped"
                print "totalvars=%d, best R^2 = %f"%(len(indexes), best_new_sco
            else:
                print "dropped = %s ..."%names_x[drop_candidate]
                print "surviving = %s ..."%names_x[variables]
                print "totalvars=%d, best R^2 = %f"%(len(indexes), best_new_sco
        return  nvars, training_errors, test_errors

nvars, training_errors, test_errors = bss(Xm, ym, Xtest, ytest, names_regre
```

```
        plt.figure(figsize=(6,6))
        plt.gca().invert_xaxis()
        plt.plot(nvars, training_errors, 'bo-', label="Training error")
        plt.plot(nvars, test_errors, 'ro-', label="Test error")
        plt.legend()
        plt.xlabel("# variables")
        plt.ylabel("MSE")
        plt.show()
```

```
No variables dropped
totalvars=9, best R^2 = 0.694371
dropped = Gleason ...
surviving = ['Lcavol' 'Lweight' 'Age' 'Lbph' 'Svi' 'Lcp' 'Pgg45'] ...
totalvars=8, best R^2 = 0.694258
dropped = Age ...
surviving = ['Lcavol' 'Lweight' 'Lbph' 'Svi' 'Lcp' 'Pgg45'] ...
totalvars=7, best R^2 = 0.682807
dropped = Lcp ...
surviving = ['Lcavol' 'Lweight' 'Lbph' 'Svi' 'Pgg45'] ...
totalvars=6, best R^2 = 0.666920
dropped = Pgg45 ...
surviving = ['Lcavol' 'Lweight' 'Lbph' 'Svi'] ...
totalvars=5, best R^2 = 0.659176
dropped = Lbph ...
surviving = ['Lcavol' 'Lweight' 'Svi'] ...
totalvars=4, best R^2 = 0.637441
dropped = Svi ...
surviving = ['Lcavol' 'Lweight'] ...
totalvars=3, best R^2 = 0.614756
dropped = Lweight ...
surviving = ['Lcavol'] ...
totalvars=2, best R^2 = 0.537516
```

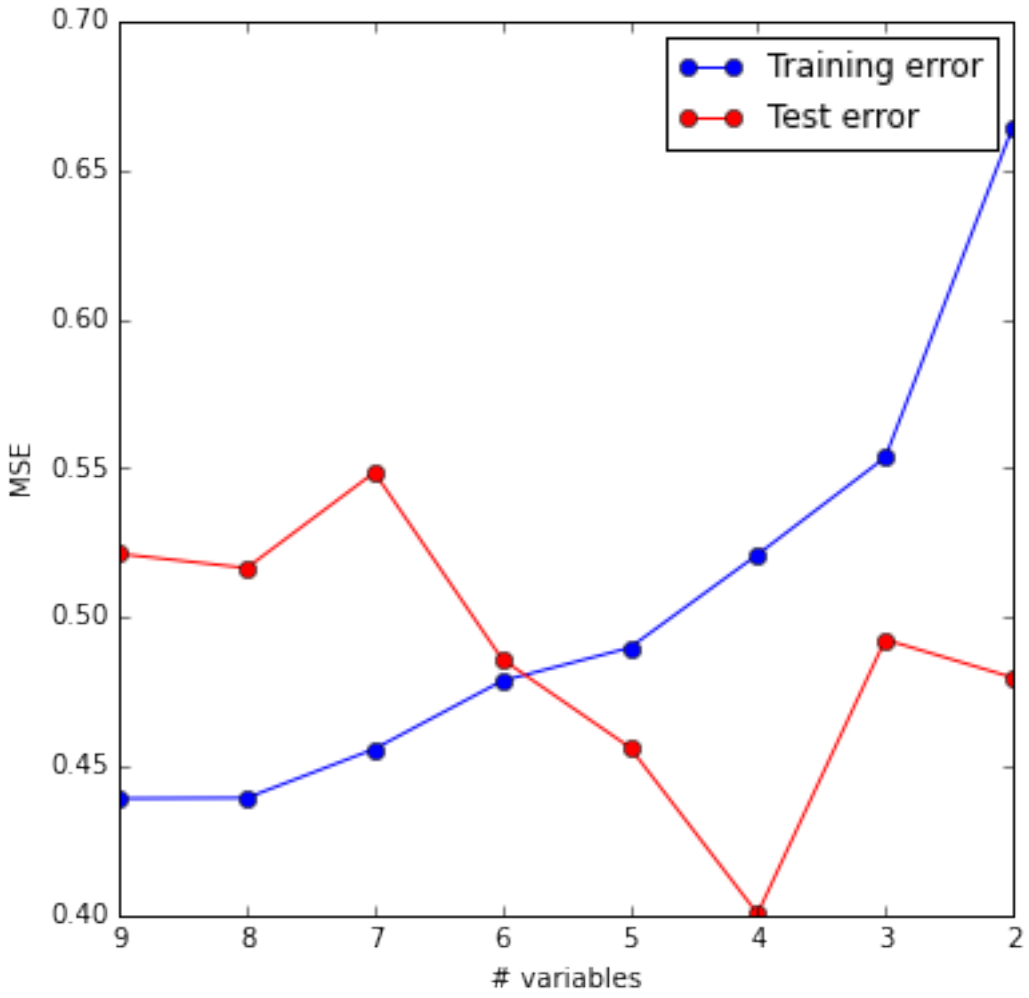

1.3 Ejercicio 3

(a) Ajuste un modelo lineal utilizando "Ridge Regression", es decir, regularizando con la norma L2. Utilice valores del parámetro de regularización lambda en el rango $[10^{-4}, 10^{-1}]$. Construya un gráfico que muestre los coeficientes obtenidos como función del parámetro de regularización. Describa lo que observa.

```
In [10]: X = X.drop('intercept', axis=1)

In [11]: from sklearn.linear_model import Ridge
         import matplotlib.pylab as plt

         Xtrain = X[istrain]
         ytrain = y[istrain]
         names_regressors = ["Lcavol", "Lweight", "Age", "Lbph", "Svi", "Lcp", "Gle
         alphas_ = np.logspace(4,-1,base=10)
```

```
coefs = []
model = Ridge(fit_intercept=True,solver='svd')

for a in alphas_:
    model.set_params(alpha=a)
    model.fit(Xtrain, ytrain)
    coefs.append(model.coef_)

ax = plt.gca()

for y_arr, label in zip(np.squeeze(coefs).T, names_regressors):
    plt.plot(alphas_, y_arr, label=label)

plt.legend()
ax.set_xscale('log')
ax.set_xlim(ax.get_xlim()[::-1]) # reverse axis
plt.xlabel('alpha')
plt.ylabel('weights')
plt.title('Regularization Path RIDGE')
plt.axis('tight')
plt.legend(loc=2)
plt.show()
```

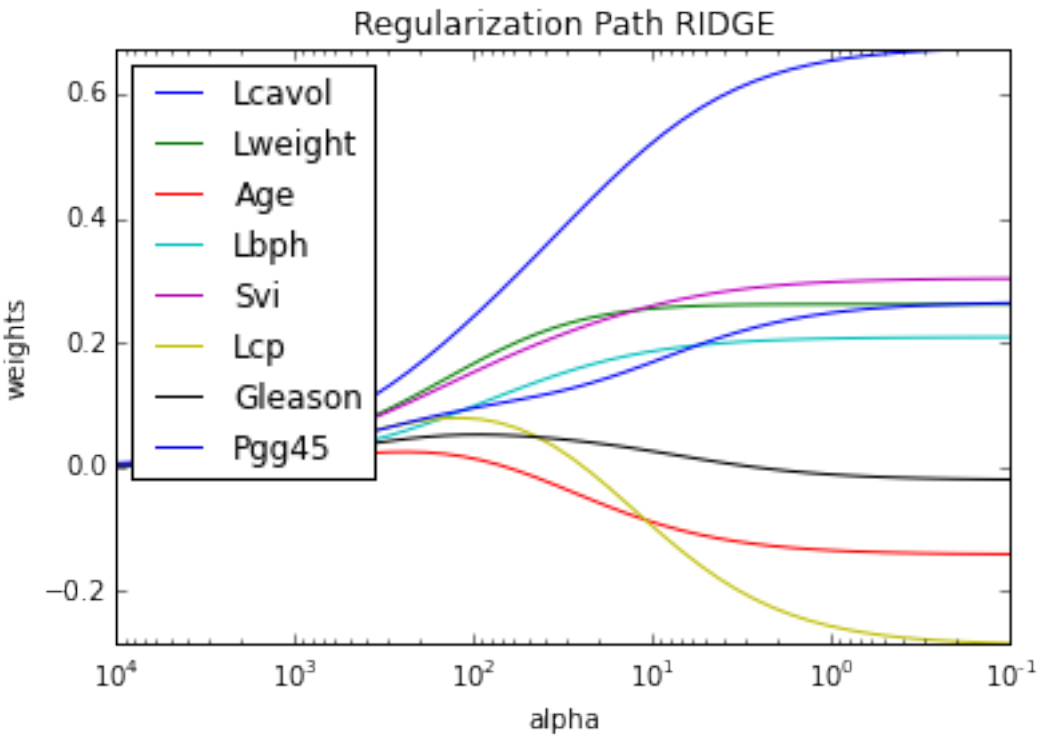

Se observa que a mayor alpha el algoritmo es más agresivo en no considerar variables (darles

peso 0). El comportamiento se estabiliza, en este caso, en 10^{-1} (se hizo experimentos con valores menores de alpha y es muy similar el resultado).

(b) Ajuste un modelo lineal utilizando el método "Lasso", es decir, regularizando con la norma L1. Utilice valores del parámetro de regularización lambda en el rango $[10^1, 10^{-2}]$. Para obtener el código, modifique las líneas 7 y 9 del ejemplo anterior. Construya un gráfico que muestre los coeficientes obtenidos como función del parámetro de regularización. Describa lo que observa. ¿Es más efectivo Lasso para seleccionar atributos?

```
In [12]: from sklearn.linear_model import Lasso
         import matplotlib.pylab as plt

         Xtrain = X[istrain]
         ytrain = y[istrain]
         names_regressors = ["Lcavol", "Lweight", "Age", "Lbph", "Svi", "Lcp", "Gle
         alphas_ = np.logspace(1,-2,base=10)
         coefs = []
         model = Lasso(fit_intercept=True)

         for a in alphas_:
             model.set_params(alpha=a)
             model.fit(Xtrain, ytrain)
             coefs.append(model.coef_)

         ax = plt.gca()

         for y_arr, label in zip(np.squeeze(coefs).T, names_regressors):
             plt.plot(alphas_, y_arr, label=label)

         plt.legend()
         ax.set_xscale('log')
         ax.set_xlim(ax.get_xlim()[::-1]) # reverse axis
         plt.xlabel('alpha')
         plt.ylabel('weights')
         plt.title('Regularization Path LASSO')
         plt.axis('tight')
         plt.legend(loc=2)
         plt.show()
```

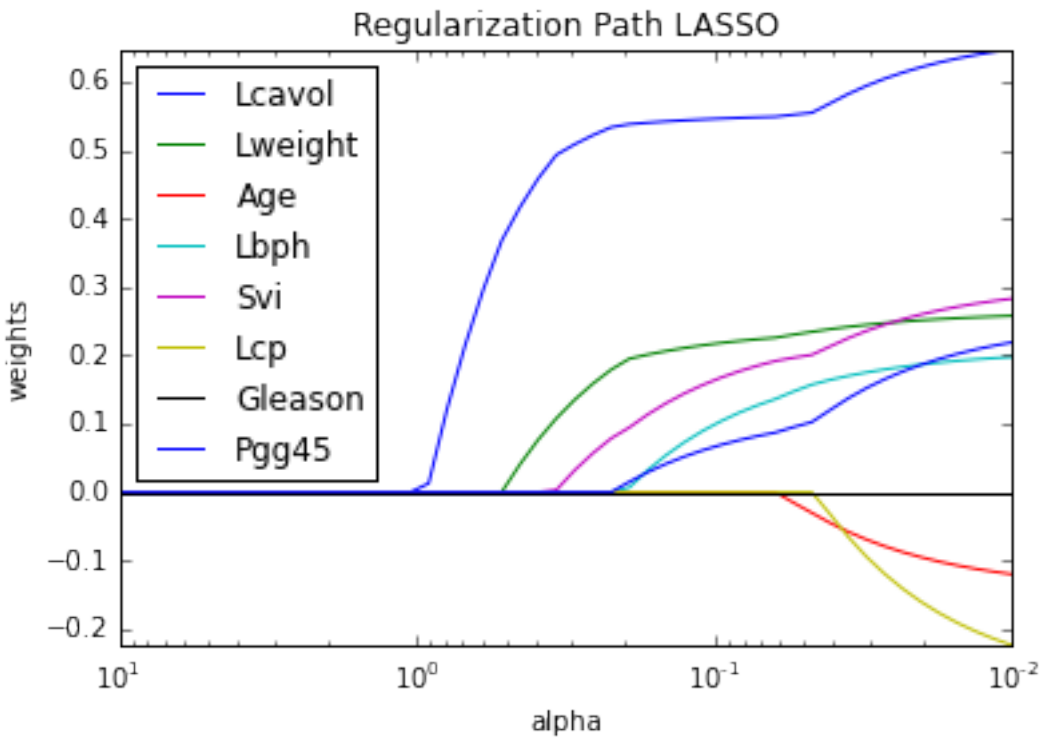

Con Lasso se anulan las variables de manera más acelerada lo cual logra que la selección del parámetro alpha se comporte, aproximadamente, como la cantidad de variables a anular.

(c) Utilizando "Ridge Regression", construya un gráfico que muestre el error de entrenamiento y el error de pruebas como función del parámetro de regularización. Discuta lo que observa.

```
In [13]: Xtest = X[np.logical_not(istrain)]
         ytest = y[np.logical_not(istrain)]
         alphas_ = np.logspace(2,-2,base=10)
         coefs = []
         model = Ridge(fit_intercept=True)
         mse_test = []
         mse_train = []

         for a in alphas_:
             model.set_params(alpha=a)
             model.fit(Xtrain, ytrain)
             yhat_train = model.predict(Xtrain)
             yhat_test = model.predict(Xtest)
             mse_train.append(np.mean(np.power(yhat_train - ytrain, 2)))
             mse_test.append(np.mean(np.power(yhat_test - ytest, 2)))

         ax = plt.gca()
         ax.plot(alphas_,mse_train,label='train error ridge')
```

```
ax.plot(alphas_,mse_test,label='test error ridge')
plt.legend(loc=2)
ax.set_xscale('log')
ax.set_xlim(ax.get_xlim()[::-1])
plt.show()

print "El error minimo se encuentra en alpha =", min(zip(mse_test, yhat_te
```

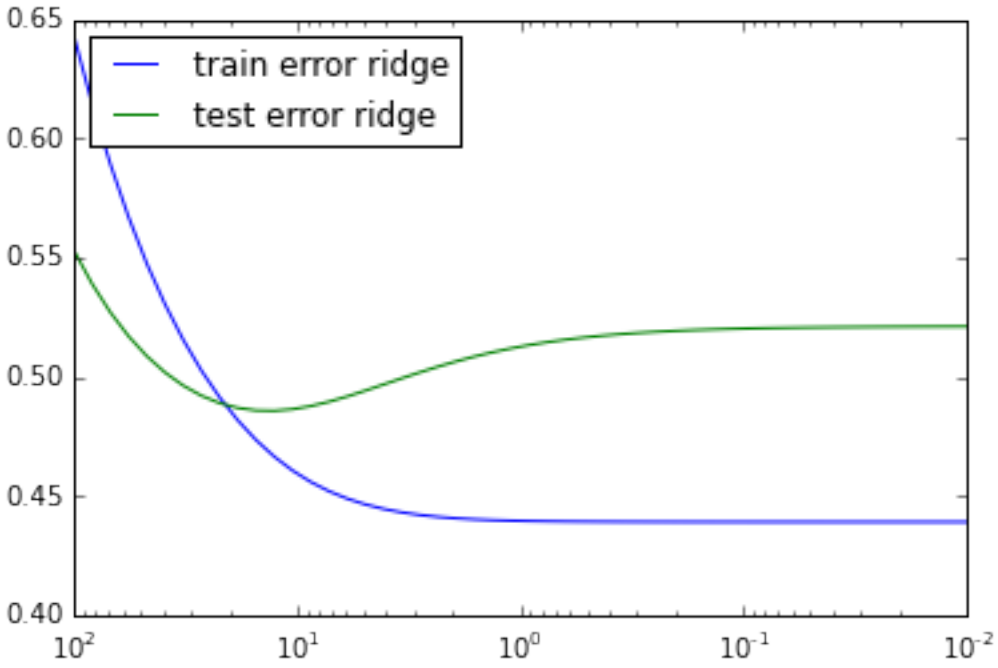


```
El error minimo se encuentra en alpha = 2.20307927232
```

El error de entrenamiento de Ridge es menor a medida que disminuye el alpha (más variables son consideradas) producto, probablemente, del sobre ajuste. Mientras tanto el error en el conjunto de prueba encuentra su optimo en un punto (en este caso en alpha igual a 2.2) lo que hace latente la necesidad de usar técnicas como cross-validation para empíricamente tener una mejor intuición de cuales son los parámetros óptimos.

(d) Utilizando "Lasso", construya un gráfico que muestre el error de entrenamiento y el error de pruebas como función del parámetro de regularización. Discuta lo que observa.

```
In [14]: Xtest = X[np.logical_not(istrain)]
         ytest = y[np.logical_not(istrain)]
         alphas_ = np.logspace(0.5,-2,base=10)
         coefs = []
         model = Lasso(fit_intercept=True)
```

```
mse_test = []
mse_train = []

for a in alphas_:
    model.set_params(alpha=a)
    model.fit(Xtrain, ytrain)
    yhat_train = model.predict(Xtrain)
    yhat_test = model.predict(Xtest)
    mse_train.append(np.mean(np.power(yhat_train - ytrain, 2)))
    mse_test.append(np.mean(np.power(yhat_test - ytest, 2)))

ax = plt.gca()
ax.plot(alphas_,mse_train,label='train error lasso')
ax.plot(alphas_,mse_test,label='test error lasso')
plt.legend(loc=2)
ax.set_xscale('log')
ax.set_xlim(ax.get_xlim()[::-1])
plt.show()
```

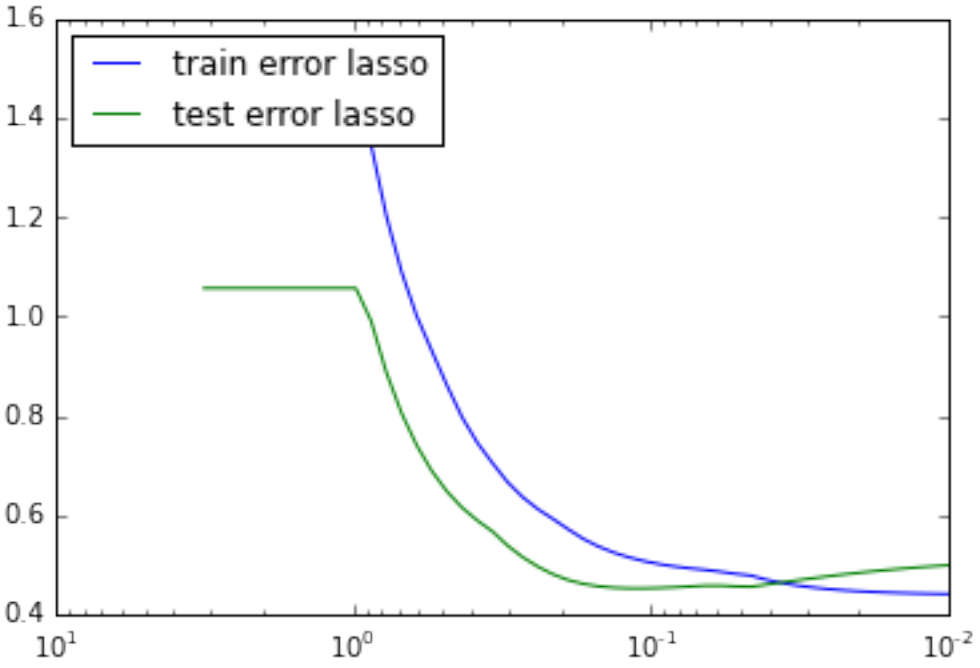

Se observa lo mismo que el ejercicio anterior pero de forma más agresiva producto de lo discutido en la pregunta (b)

(e) Estime el valor del parámetro de regularización en los métodos anteriores usando validación cruzada.

```
In [15]: def MSE(y,yhat): return np.mean(np.power(y-yhat,2))
         Xm = Xtrain.as_matrix()
```

```
        ym = ytrain.as_matrix()
        k_fold = cross_validation.KFold(len(Xm),10)
        best_cv_mse = float("inf")
        model = Lasso(fit_intercept=True)

        for a in alphas_:
            model.set_params(alpha=a)
            mse_list_k10 = [MSE(model.fit(Xm[train], ym[train]).predict(Xm[val]),
            for train, val in k_fold]
            if np.mean(mse_list_k10) < best_cv_mse:
                best_cv_mse = np.mean(mse_list_k10)
                best_alpha = a

        print "BEST PARAMETER=%f, MSE(CV)=%f"%(best_alpha,best_cv_mse)
```

```
BEST PARAMETER=0.010000, MSE(CV)=0.758661
```

2 Ejercicio 4

(a) Lea los archivos de datos y cárguelos en dos dataframe o matrices X, y. En el caso de X es extremadamente importante que mantenga el formato disperso (sparse) (¿porqué?).

```
In [16]: import os.path
         data_base_path = "./data"
         import pandas as pd
         import numpy as np
         from scipy.sparse import csr_matrix
         from scipy.io import mmread

         X_train = csr_matrix(mmread(os.path.join(data_base_path, 'train.x.mm')))
         y_train = np.loadtxt(os.path.join(data_base_path, 'train.y.dat'))

         X_dev = csr_matrix(mmread(os.path.join(data_base_path, 'dev.x.mm')))
         y_dev = np.loadtxt(os.path.join(data_base_path, 'dev.y.dat'))

         X_test = csr_matrix(mmread(os.path.join(data_base_path, 'test.x.mm')))
         y_test = np.loadtxt(os.path.join(data_base_path, 'test.y.dat'))
```

Se usa una matriz sparse ya que, producto de que hay muchos datos vacios (normal en texto). Así se comprime la matriz y queda en un tamaño manejable.

(b) Construya un modelo lineal que obtenga un coeficiente de determinación (sobre el conjunto de pruebas) de al menos 0.75.

```
In [17]: X_train.get_shape()
```

```
Out[17]: (1147, 145256)
```

Se observa que hay 1147 peliculas cada una con 145256 atributos.

```
In [18]: #from sklearn.preprocessing import StandardScaler

         #x_scaler = StandardScaler(with_mean=False)

         #X_train = x_scaler.fit_transform(X_train, y_train)
         #X_test = x_scaler.transform(X_test, y_test)
```

Se prueba escalar los datos pero esto devuelve peores resultados.

```
In [19]: from sklearn.feature_selection import SelectKBest, chi2

         ch2 = SelectKBest(chi2, k=29000)

         X_train = ch2.fit_transform(X_train, y_train)
         X_dev = ch2.transform(X_dev)
         X_test = ch2.transform(X_test)
```

Se utiliza la extracción de caracteristicas KBest mediante la metrica chi cuadrado. Esto ya que documentación de sklearn muestra que es utilizada cuando la data esta basada en texto (como es el caso).

La cantidad de catacteristicas se obtiene mediante prueba y error.

Fuente: http://scikit-learn.org/stable/auto_examples/text/document_classification_20newsgroups.html#ex text-document-classification-20newsgroups-py

```
In [20]: import sklearn.linear_model as lm

         model = lm.LinearRegression(fit_intercept = False)
         model.fit(X_train, y_train)

         print "R2=%f" % model.score(X_test, y_test)
```

```
R2=0.600107
```

Con una regresión linear ordinaria se logra un R^2 de 0.6.

```
In [21]: import sklearn.linear_model as lm

         model = lm.LassoCV(n_jobs=7)

         model.fit(X_train, y_train)

         print "R2=%f" % model.score(X_test, y_test)
```

```
R2=0.504787
```

Se prueba además con Lasso pero se obtiene peor resultados. Normalizar los datos no cambia en nada el R^2. Se utiliza la clase LassoCV que recorre varios valores de alpha y elije el mejor en el conjunto de entrenamiento. El alpha de Lasso es:

```
In [22]: model.alpha_

Out[22]: 15405802.603399234

In [23]: import sklearn.linear_model as lm

         model = lm.RidgeCV()

         model.fit(X_train, y_train)

         print "R2=%f" % model.score(X_test, y_test)

R2=0.563866
```

Tampoco tenemos suerte con Ridge.
El alpha de Ridge es:

```
In [ ]: model.alpha_

Out[ ]: 10.0
```

Se prueba con ElasticNet que mezcla ambos modelos:

```
In [ ]: import sklearn.linear_model as lm

        model = lm.ElasticNetCV(l1_ratio=np.arange(0, 1, 0.1), alphas=np.arange(0,

        model.fit(X_train, y_train)

        print "R2=%f" % model.score(X_test, y_test)

/usr/lib64/python2.7/site-packages/sklearn/linear_model/coordinate_descent.py:466:
  ConvergenceWarning)
...
```

Y luego se ejecuta en un rango más acotado conforme a los optimos obtenidos anteriormente:

```
In [ ]: import sklearn.linear_model as lm

        model = lm.ElasticNetCV(l1_ratio=np.arange(0, 0.1, 0.01), alphas=np.arange

        model.fit(X_train, y_train)

        print "R2=%f" % model.score(X_test, y_test)
```

Se obtienen el mejor resultado hasta el momento.

A continuación en vez de realizar cross-validation se usa el conjunto de validación ("dev") y modificando los parametros manualmente:

```
In [ ]: import sklearn.linear_model as lm

        model = lm.ElasticNet(alpha = 0.05, l1_ratio=0.775)
        model.fit(X_train, y_train)

        print "R2=%f" % model.score(X_dev, y_dev)
```

Dando:

```
In [ ]: print "R2=%f" % model.score(X_test, y_test)
```

Cabe mencionar que se probo con tecnicas como Grid Search y Randomized Parameter Optimization pero sus tiempos de computo fueron excesivos.

```
In [ ]: (0.634180)**0.5
```

Esto implica un R de 0.796 aproximadamente.

3 Conclusiones

En regresiones donde los datos tienen múltiples dimensiones es fundamental tener mecanismos de reducir la dimensionalidad. Esto se puede realizar de forma directa (mediante agregar o remover variables) o indirecta (mediante Lasso o Ridge). Elegir el algoritmo depende de los datos y que tan agresivo queremos que sea la reducción, entendiendo que Lasso elimina más repentinamente dimensiones que Ridge.

Técnicas combinadas que ensamblen diferentes algoritmos dan mejores resultados, al menos en el caso estudiado, que las técnicas individuales.

La validación de los modelos que uno genera es importante para evitar falsas ilusiones de éxito. Técnicas como cross validation ayudan a entender la sensibilidad en el modelo dada una variación en el conjunto de entrenamiento.

Además es fundamental la elección de parámetros. Elegir la mejor combinación de estos para un algoritmo puede significar mejoras importantes en la calidad del resultado y se presenta como un problema abierto de investigación.

```
In [ ]:
```